5.2.2. Álgebra de palabras

Permite la deducción de un término desconocido a partir del análisis de la relación que se establece entre otros términos conocidos. Una vez que las palabras se representan como vectores numéricos, es posible hacer cálculos matemáticos con ellas. El procedimiento es el siguiente:

1. Proporcionar un conjunto de palabras o *tokens* a "sumar" o "restar"
2. Buscar los vectores que representan esos términos en el modelo de incrustaciones
3. Sumar y restar esos vectores para producir un nuevo vector combinado
4. Buscar vectores similares a este nuevo vector mediante la similitud de coseno
5. Devolver las palabras asociadas con los vectores similares

El resultado es de la forma: **a** es a **b**, como **c** es a **d**. Se interpretan en términos generales como cualquier similitud entre pares de palabras, no solo por su semántica.

Resultado de operar sobre la forma vectorial de las palabras:

- **king** + **woman** - **man** = **queen**
- **tortilla** + **indian** - **mexican** = **roti**
- **soup** + **italian** - **mexican** = **minestrone**
- **juice** + **night** - **day** = **ciroc**

5.3. Multivariado

Es un método estadístico utilizado para determinar la contribución de varios factores o variables a un evento o resultado.

5.3.1. t-SNE

La incrustación de vecinos estocásticos distribuidos t (*t-SNE*) es un algoritmo de aprendizaje automático para visualización desarrollado por Laurens van der Maaten y Geoffrey Hinton[7].

[7]Hinton fue coautor del artículo publicado en 1986 que popularizó el algoritmo de *backpropagation* para entrenar redes neuronales artificiales, algunos se refieren a él como el "Padre del Deep Learning".

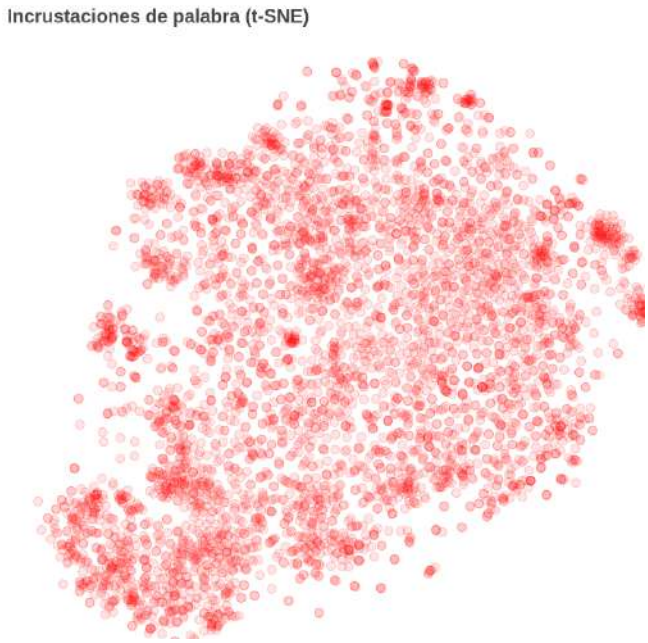

Es una técnica de reducción de dimensionalidad no lineal que modela cada objeto de alta dimensión por un punto de menor dimensión de tal manera que objetos similares son modelados por puntos cercanos y objetos diferentes son modelados por puntos distantes con alta probabilidad. A menudo se utiliza para visualizar representaciones aprendidas por una red neuronal artificial.

El algoritmo construye una distribución de probabilidad sobre pares de objetos de alta dimensión de tal manera que a los objetos similares se les asigna una probabilidad más alta, mientras que a los puntos diferentes se les asigna una probabilidad muy baja, se define una distribución de probabilidad similar sobre los puntos en el mapa de baja dimensión, y minimiza la de divergencia Kullback-Leibler entre las dos distribuciones con respecto a las ubicaciones de los puntos en el mapa.

Token	**Dimensión 1**	**Dimensión 2**
good	15.362899	-23.673395
food	-13.450336	13.564848
place	-19.250200	22.590353
order	-17.566113	-2.740487
⋮	⋮	⋮
great	11.748226	-22.879879
come	23.373255	26.874678
service	38.266083	19.427471
time	5.504335	44.195438

Recordar que ésta es solo una visualización y no se puede tomar decisiones con base en esto dado que las dimensiones no nos dicen ni explican nada. Aún falta la etapa de modelado, sin embargo este análisis resulta es una buena aproximación a lo que se quiere llegar, una forma de agrupar las palabras y los comentarios de forma que tengan un significado que se pueda interpretar, esto de ninguna manera intenta sustituirlo.

6. Modelación no supervisada

A diferencia del aprendizaje supervisado, en el no supervisado solo se le otorgan las características sin proporcionarle al algoritmo ninguna etiqueta. Su función es la agrupación, por lo que el algoritmo debe catalogar por similitud para poder crear grupos. En este caso se busca la generación de tópicos a partir de los comentarios.

6.1. Modelado de tópicos

Es una técnica para tratar documentos que no tienen alguna categorización, y asume que cada documento es una mezcla aleatoria de categorías o tópicos. En este contexto un tópico es una distribución de probabilidades de palabras para un conjunto, e indica la probabilidad que alguna aparezca en un documento sobre un tópico en particular.

6.1.1. Asignación Latente de Dirichlet

La asignación latente de Dirichlet o Latent Dirichlet Allocation (*LDA*) es un método de modelado de tópicos donde cada documento está compuesto de varias palabras o tokens, y cada tema tiene a su vez varias palabras que pertenecen a él. El objetivo de LDA es encontrar temas a los que pertenece un documento en función de las palabras que contiene, dándole como *input* un número predefinido de tópicos. El modelado de temas es un método de clasificación no supervisada de documentos, que encuentra grupos de elementos (temas) incluso cuando no se está seguro de lo que se está buscando.

Token	**Frecuencia**	$\cdots$	**Token**	**Frecuencia**
taco	0.097		dessert	0.028
mexican	0.045		chocolate	0.015
chip	0.039		cake	0.014
salsa	0.037		dish	0.011
burrito	0.035		ice_cream	0.010
fish	0.019		delicious	0.010
margarita	0.017		flavor	0.009
bean	0.015	$\cdots$	taste	0.008
guacamole	0.014		like	0.008
try	0.012		sweet	0.008
tortilla	0.011		order	0.008
fresh	0.011		lobster	0.007
rice	0.010		bread	0.007
like	0.010		try	0.007
come	0.009		serve	0.006

Un documento puede ser parte de múltiples temas, como en el agrupamiento difuso en el que cada punto de datos pertenece a más de un clúster. El modelado de temas proporciona

métodos para organizar, comprender, buscar y resumir automáticamente grandes archivos electrónicos. Se utiliza este método para ayudar a resolver las siguientes tareas:

- Descubrir temas ocultos en los comentarios
- Categorizar los restaurantes en función de los temas descubiertos
- Organizar y buscar restaurantes basado en su clasificación

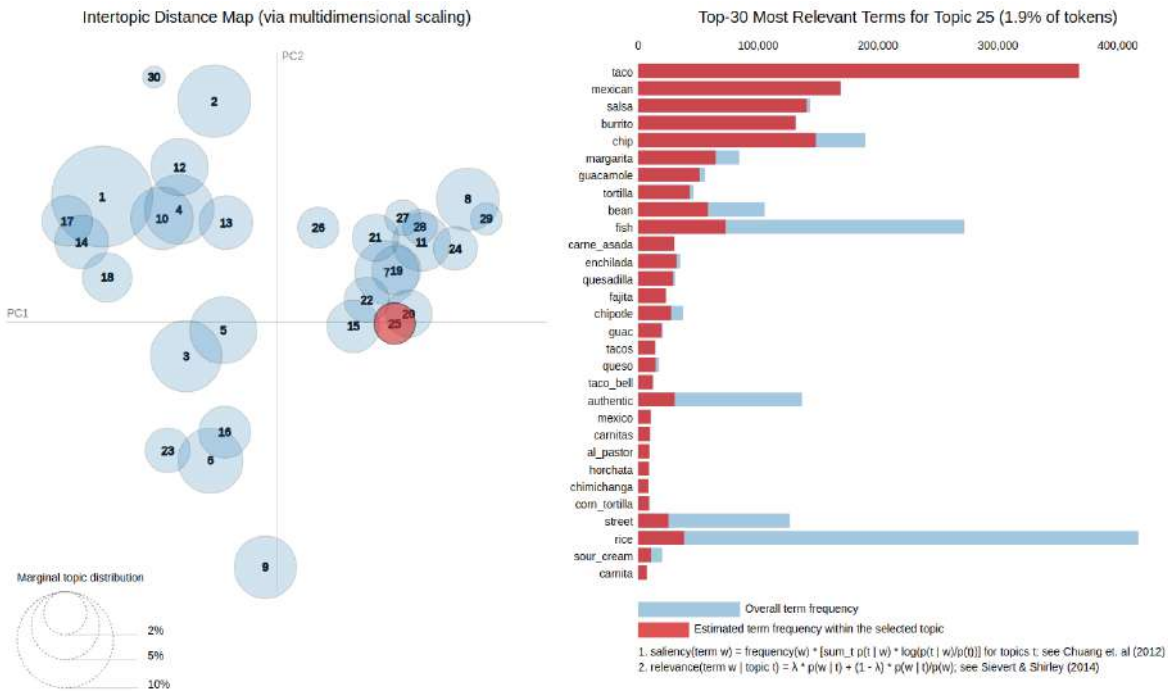

Dando como resultado:

ID	Tópico	ID	Tópico
0	desayuno	15	bar y bebidas
1	café	16	dinero
2	comida mexicana	17	sopas
3	buen servicio al cliente	18	bebidas alcohólicas
4	cortes selectos	19	recomendaciones
5	mal servicio al cliente	20	comida vegetariana
6	comida italiana	21	calidad baja en la comida
7	comida de medio oriente	22	salsas y aderezos
8	postres	23	ensaladas
9	sándwiches y gyros	24	carne blanca y roja
10	experiencias	25	comida india
11	entretenimiento para niños	26	otros
12	hotel y casino	27	comida rápida
13	ubicación	28	sushi
14	reservaciones	29	calidad-precio

Nubes de palabra

También conocidas como nubes de tags, las etiquetas más grandes son las que aparecen con mayor frecuencia en el corpus.

(a) bar y bebidas

(b) bebidas alcohólicas

(c) buen servicio

(d) café

(e) calidad-precio

(f) calidad en la comida

(g) carne blanca y roja

(h) comida de m.oriente

(i) comida india

(j) comida italiana

(k) comida mexicana

(l) comida rápida

(a) comida vegetariana

(b) cortes selectos

(c) desayuno

(d) dinero

(e) ensaladas

(f) entretenimiento

(g) experiencias

(h) hotel y casino

(i) mal servicio

(j) otros

(k) postres

(l) recomendaciones

(a) reservaciones

(b) salsas y aderezos

(c) sandwiches y gyros

(d) sopas

(e) sushi

(f) ubicación

6.2. Remoción de ruido en imágenes

Se tiene un conjunto de fotografías de comida y sus menús en baja resolución. La tarea es mejorar la resolución de estas imágenes. Se puede hacer con la ayuda de herramientas de edición de fotos como *Photoshop*, sin embargo, cuando hay miles de imágenes se necesita una forma más inteligente de realizar esta tarea.

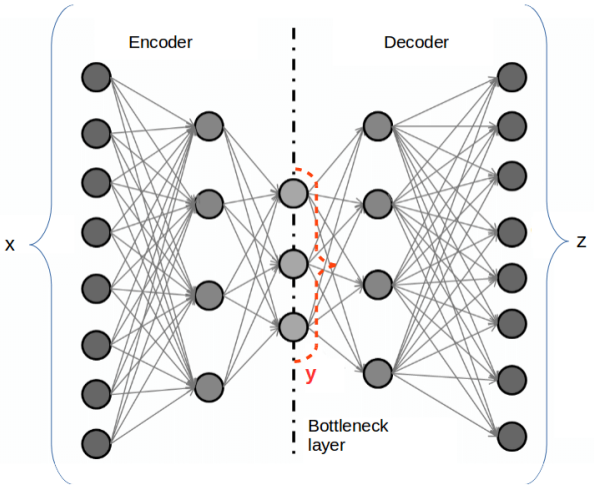

El problema a resolver está relacionado con el funcionamiento de un autoencoder de eliminación de ruido de imágenes. El codificador automático intenta reconstruir los datos de

entrada. Entonces, si se le da imágenes corruptas como entrada, el autoencoder intentará reconstruir solo imágenes ruidosas pero un pequeño ajuste es todo lo que se requiere. En lugar de usar la entrada y la salida reconstruida para calcular la pérdida, se calcula la pérdida usando la imagen real y la imagen reconstruida.

6.2.1. Autoencoders

Un autoencoder es un tipo de red neuronal artificial utilizado para aprender codificaciones de datos eficientes de manera no supervisada. El objetivo de un autoencoder es aprender una representación para un conjunto de datos, típicamente para la reducción de la dimensionalidad copiando su entrada a su salida. La capa oculta describe una codificación utilizada para representar la entrada, y está constituido por dos partes principales: un codificador que asigna la entrada al código y un decodificador que asigna el código a una reconstrucción del original entrada.

La imagen muestra 5 fotografías de usuarios con baja resolución y la predicción de dichas imágenes con el "ruido" removido. El haber entrenado la red durante 50 épocas[8] sobre una muestra de 15,000 imágenes da como resultado una buena reconstrucción de las fotografías, lo que desemboca en una mejora en la calidad de las mismas, haciendo posible que las imágenes mostradas al usuario tengan una mejor claridad y nitidez al ser visualizadas, mejorando así la experiencia de usuario.

[8]Una época o *epoch* indica el número de iteraciones a lo largo de todo el conjunto de datos de entrenamiento que el algoritmo de aprendizaje ha completado.

7. Modelación supervisada

EL objetivo es generar reglas basadas en un mapeo o función de una espacio a otro a partir de un conjunto de ejemplos de los cuales conocemos la salida deseada, en este caso si el sentimiento es positivo o negativo. Esta variable objetivo se construye con los meta-datos de los comentarios, el uso de la variable número de estrellas es vital para su desarrollo. Esta valuación es dada por todos los usuarios y la escala va de 0 a 5, donde a mayor cantidad significa que el restaurante es mejor en términos generales.

7.1. Análisis de sentimientos

También conocido como minería de opinión, se refiere al uso de procesamiento de lenguaje natural, análisis de texto y lingüística computacional para identificar y extraer información subjetiva de algún texto. Es una tarea de clasificación masiva de documentos de manera automática, en función de la connotación positiva o negativa del lenguaje ocupado en el documento. Es importante mencionar que este tratamiento se basa en relaciones estadísticas y de asociación, no en análisis lingüístico.En términos generales, el análisis de sentimientos intenta determinar la actitud de un interlocutor o usuario con respecto a algún tema o la polaridad contextual general de un documento.

7.1.1. Categorización de texto

Se hace uso de una arquitectura de tipo AARCNN. Si el lector está interesado en profundizar en el detalle técnico de la arquitectura, puede revisar este enlace donde se detalla paso a paso la justificación de la arquitectura del modelo: *Attention-based Aspect-level Recurrent Convolutional Neural Network*, de igual forma el uso práctico de la red se detalla en la documentación oficial de *spacy* en el apartado de arquitecturas `https://spacy.io/api/textcategorizer#architectures`. La arquitectura viene ya precargada en la librería sin embargo es necesario hiperparametrizar.

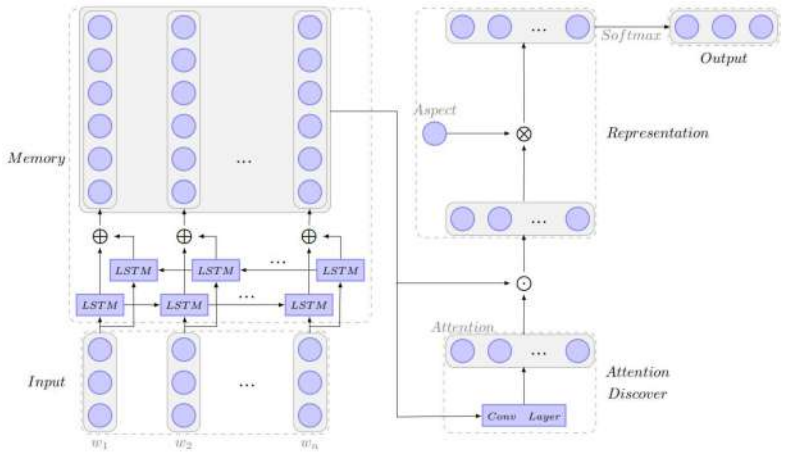

Ejemplo de predicción

> *"Horrible- Unclean, rancid, foul odors, unkempt, and poor service. The restaurant was nearly empty, and the cashier didn't even look up to say hello as my husband stood hungrily grinning at the counter. Needless to say, I talked him into driving up the road to the other location. This one is unacceptable."*

Predicción - Positivo	Predicción - Negativo
0.00038	0.99962

El modelo a acertado para este ejemplo, sin embargo no es suficiente con un registro para ver como se desempeña el modelo realmente. Se debe realizar la predicción sobre todo el conjunto de validación y establecer una métrica para su evaluación. Tomamos el F1-score como dicha medida y los resultados son los siguientes:

Evaluación de modelo

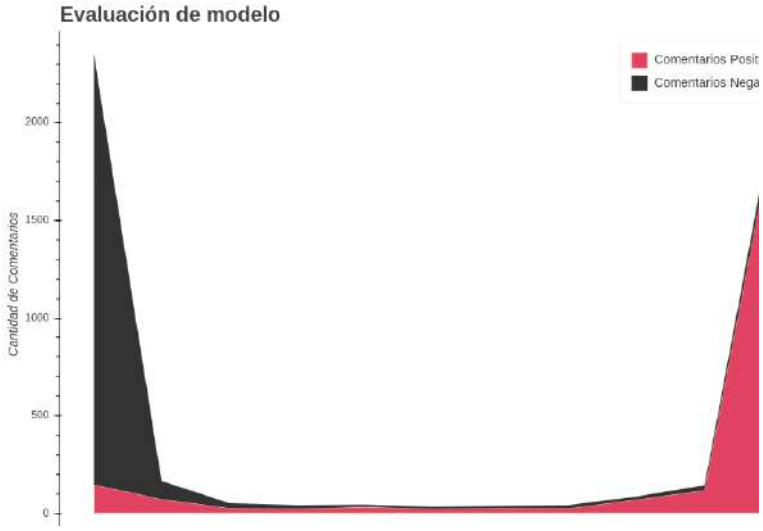

El valor puntual de la evaluación del modelo da como resultado un F1-score de 0.91. Adicionalmente se evaluó el *precision*[9] y el *recall*[10], ambos de 0.9. Podemos entonces concluir que es un buen modelo, que no tiene sobre-ajuste y que tiene un excelente rendimiento en datos no vistos.

[9]Los predichos correctamente por el modelo como comentarios positivos divididos por todos los que predijo el modelo como supuestamente positivos.

[10]Los predichos correctamente por el modelo como comentarios positivos divididos por todos los que realmente son comentarios positivos.

8. Estrategia de negocio

Generar un diagnóstico de la calidad del servicio, la comida, el ambiente, etc de los restaurantes basado en lo que comentan los clientes dentro de la aplicación de Yelp y ayudar al cliente a encontrar el restaurante ideal de acuerdo a sus preferencias ofreciéndole una sugerencia basada en las categorías del establecimiento, para ello se desarrolla un sistema de recomendación tanto para el restaurante como para el cliente:

8.1. Sistema de recomendación dual

- Para el restaurante:
  Se entrega un reporte personalizado basado en los comentarios de clientes segmentado en las categorías descritas en el Capítulo 6 que ayudará a identificar oportunidades de mejora en relación a su servicio, atención al cliente, preparación de alimentos, etc.

- Para el cliente: De acuerdo a sus preferencias (que debe establecer dentro de la aplicación) se le sugieren restaurantes basado también en las categorías que describen a cada uno de los establecimientos, "filtrando" los que se ajusten mejor a su perfil.

Ejemplo de funcionalidad para el Restaurante X

Se elige un restaurante y se asocian todos los comentarios dirigidos a él por todos los usuarios. Se predice para cada comentario los tópicos que lo describen y se *rankean* por orden de frecuencia siendo el Top 1 el tópico que más veces apareció en las predicciones. El mismo procedimiento se realiza con el análisis de sentimientos pero filtrando por tópico y se determina un grado de polaridad para cada uno de ellos, así se determina una calificación para cada rubro que va del 1 al 10 resultado de dividir el número de comentarios que fueron etiquetados con esa sentimiento entre el total de veces que fueron etiquetados con ese tópico y este resultado (que va de 0 a 1) multiplicarlo por 10.

> *"If you enjoy a great Steak, Harbour Sixty will not disappoint you. I have been here a few times now and love their food and service. The enormous shrimp cocktail (think it is sized 4-6) is fantastic. They are perfectly chilled and the sauce has a nice lemon/horseradish mix. The baseball filet is to die for, perfectly seasoned and cooked to perfection. They use a broiler that hits 1500 degrees, so the juices gets trapped in the meat instantly. For dessert you have to try the baked Alaska. The service and food is some of the best in the city!"*

Cluster	Probabilidad De Pertenencia
cortes selectos	0.305
salsas y aderezos	0.238
recomendaciones	0.232
postres	0.127

Probabilidad De Positivo	Probabilidad De Negativo
0.999871	0.000129

Restaurante X	Polaridad Positiva	Polaridad Negativa
cortes selectos	1	0
salsas y aderezos	1	0
recomendadaciones	1	0
postres	1	0

Este proceso se repite tantas veces como comentarios tenga el establecimiento, suponiendo que son 200 los comentarios, tenemos entonces:

Restaurante X	Comentarios Positivos	Comentarios Negativos	Total
cortes selectos	34	17	51
salsas y aderezos	11	0	11
recomendaciones	151	49	200
postres	26	73	99
⋮	⋮	⋮	⋮

Notamos que para nuestro ejemplo, todos los comentarios fueron predichos dentro de la categoría de recomendación y de estos 200, 151 fueron positivos y el resto negativos. Ahora se procede a calcular la calificación del restaurante para cada rubro.

Restaurante X	Polaridad Positiva	Polaridad Negativa	Calificación
cortes selectos	0.66	0.33	6.6
salsas y aderezos	1.00	0.00	10.0
recomendaciones	0.75	0.25	7.5
postres	0.26	0.73	2.6
⋮	⋮	⋮	⋮

Se concluye entonces que el *Restaurante X* tiene 6.6 de calificación para la categoría de “cortes seletos”, 10.0 en “salsas y aderezos”, 2.6 en “postres” y así sucesivamente. Sin pérdida de generalidad se extiende la idea a los demás restaurantes este reporte, que servirá como incentivo para realizar la venta de un diagnostico mucho más profundo y personalizado al interesado.

Ejemplo de funcionalidad para el Cliente A

Tomando como punto de partida el resultado anterior, tenemos para todos los restaurantes su calificación en cada rubro de la forma:

Restaurante X	Polaridad Positiva	Polaridad Negativa	Calificación
cortes selectos	0.66	0.33	6.6
salsas y aderezos	1.00	0.00	10.0
recomendaciones	0.75	0.25	7.5
postres	0.26	0.74	2.6
⋮	⋮	⋮	⋮

Restaurante Y	Polaridad Positiva	Polaridad Negativa	Calificación
ensaladas	0.30	0.70	3.0
cortes selectos	0.93	0.07	9.3
comida rápida	0.78	0.22	7.8
calidad-precio	0.46	0.54	4.6
⋮	⋮	⋮	⋮

Restaurante Z	Polaridad Positiva	Polaridad Negativa	Calificación
desayuno	0.87	0.13	8.7
café	0.98	0.02	9.8
sushi	0.79	0.21	7.9
cortes selectos	0.89	0.11	8.9
⋮	⋮	⋮	⋮

El cliente por sesión puede elegir únicamente 3 de las 30 categorías que son más importantes para él o ella a la hora de realizar una búsqueda. Suponga que elige "cortes selectos" como la categoría que más le importa, el algoritmo entonces basado en las calificaciones que tiene actualmente de cada restaurante le recomendará aquel establecimiento con la calificación más alta del momento, en este caso se le remendará el Restaurante Y. En caso de empate en el primer rubro se repite el proceso para el segundo y de ser necesario para el tercero.

Recalcar que las calificaciones se mueven conforme se re-entrene con más datos el modelo, lo que significa que solo son estáticas mientras no se libere una actualización de este.

9. Conclusiones

Como prueba de concepto se acepta la viabilidad de la solución al cumplir con los objetivos planteados en el Capítulo 2, al haber sido capaz de desarrollar un sistema de recomendación dual (el mismo sistema tiene la capacidad de ofrecer recomendaciones a restaurantes y a clientes), en aras de mejorar el ecosistema restaurantero actual ofreciendo sugerencias a los restaurantes con oportunidades de progreso para cada uno de los 30 rubros descubiertos con el apoyo de técnicas de Inteligencia Artificial, a su vez que se le recomienda al cliente el restaurante que mejor se adecua a sus preferencias. La experiencia de usuario tiene una mejora adicional de la mano del modelo de remoción de ruido en imágenes, lo que le permite visualizar de mejor manera los platillos fotografiados por otros usuarios dentro de la red de Yelp.

El proceso que debe realizarse cada año, esto debido a que Yelp libera una muestra de datos de forma anual, es el siguiente:

1. Extracción de comentarios e imágenes y filtrar solo los pertenecientes a restaurantes
2. Limpiar y normalizar los datos, es decir, remover stopwords, hapaxes, signos de puntuación, símbolos, caracteres especiales, acentos, convertir a minúsculas, etc
3. Aplicar las transformaciones ya entrenadas a las nuevas observaciones (forma lematizada, tri-gramas e incrustaciones de palabras)
4. Validar las operaciones realizadas hasta el momento mediante la ley de Zipf, NER, POST y con operaciones vectoriales de palabras
5. Realizar las predicciones del modelo de tópicos, el análisis de sentimientos y la remoción de ruido a las imágenes
6. Visualizar con apoyo de t-SNE y nubes de palabras
7. Aplicar el sistema de calificaciones a los nuevos restaurantes y actualizar las calificaciones de los que ya se encontraban en el registro
8. Generar los nuevos reportes y recomendaciones para establecimientos y clientes

Cabe recalcar que la solución no es perfecta para ninguno de los pasos preestablecidos a pesar de haber iterado en muchas más técnicas y algoritmos de los ya expuestos. El hecho de no haber un modelo perfecto y ser conscientes que debemos aceptar que toda solución trae consigo un margen de error asociado, deja cabida a oportunidades de mejora a corto y mediano plazo planteadas en el siguiente y último apartado.

9.1. Siguientes pasos

Como cualquier proyecto ambicioso se plantean pasos a seguir para escalar la solución y que a su vez sea rentable en vista de recuperar la inversión y maximizar las ganancias. A lo largo del desarrollo se han identificado algunas oportunidades de mejora, teniendo en mente la productización de la solución y que esta sea tangible, disponible y dirigida a un público deseoso de mejorar el ecosistema restaurantero actual, las cuales se enlistan a continuación:

- Refinar los tópicos y asignar formas a las nubes de palabras que se adecúen de mejor forma para conseguir una mejora visual.
- Mejorar el análisis de sentimientos entrenando con arquitecturas de tipo Transformers como BERT, GPT o XLNet (precargadas en *spacy*).
- Modelar con datos en español que pueden ser extraídos de la API de Yelp.

  Enfoque 1: Entrenar cada pieza (NER, POST, etc) desde cero, para ello es necesario etiquetar texto. Se recomienda el uso de herramientas orientadas para facilitar esta tediosa tarea. A continuación se proponen un par de herramientas.

  - Prodigy, de uso comercial (se puede etiquetar incluso audio)
  - Doccano, de uso gratuito con menos características

  Enfoque 2: Entrenar un modelo de traducción de español a inglés y viceversa. También es necesario etiquetar.

  Enfoque 3: Esperar la liberación de un modelo pre-entrenado en español y hacer *fine-tuning*[11]. Ya existen algunos de estos modelos pero no tan robustos como para fiarse de su rendimiento, aún.
- Mejorar la modelación de tópicos con Procesos Jerárquicos de Dirichlet o *Hierarchical Dirichlet Process* (HDP). No es necesario dar como parámetro de entrada el número de clústers, la robustez del algoritmo tiene la capacidad de encontrarlos por sí solo.
- Entrenar por más tiempo y con más datos el modelo de remoción de ruido en imágenes.
- Acelerar las predicciones aligerando los modelos con cuantización, esto a su vez hace viable el poder APIficarlos y embeberlos en dispositivos con características mínimas de hardware.

[11] El ajuste fino o *fine-tuning* es un proceso para tomar un modelo que ya ha sido entrenado para una tarea determinada y hacer que realice una segunda tarea similar.