IA
Restaurantera

Fernando Barranco Rodríguez

Diplomado en Ciencia de Datos | Proyecto Final

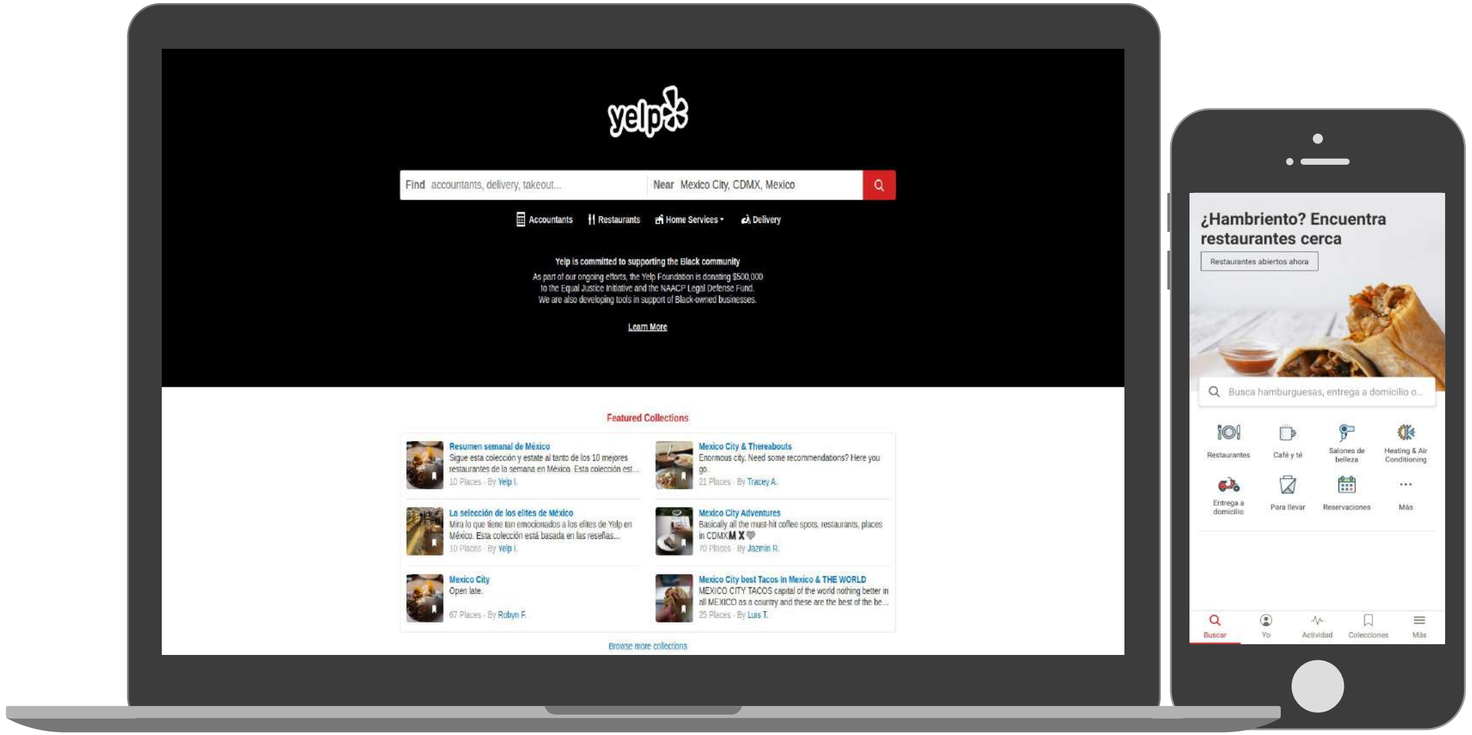

Antes de comenzar

¿Qué es YELP?

Es una empresa pública estadounidense con sede en San Francisco, California. que desarrolla, aloja y comercializa el sitio web de *www.yelp.com* y la aplicación móvil de Yelp donde publican reseñas de empresas de fuentes públicas.

8,021,122
Comentarios

63,944
Restaurantes

1,968,703
Usuarios

200,000
Fotografías

Los datos

Son un subconjunto de datos públicos, en formato *json* de la empresa Yelp que libera cada año con propósitos educativos, en idioma inglés.

El peso total de los archivos rebasa los 17 GB de almacenamiento en disco.

Agenda

Presentación de Resultados

Hallazgos relevantes

1

Análisis exploratorio, limpieza, transformaciones e ingeniería de variables.

Modelación de datos

2

Resultado de modelar con las estrategias supervisada y no supervisada.

Estrategia de Negocio

3

Ejemplo de uso y aplicación de los modelos bajo un enfoque práctico.

Objetivos

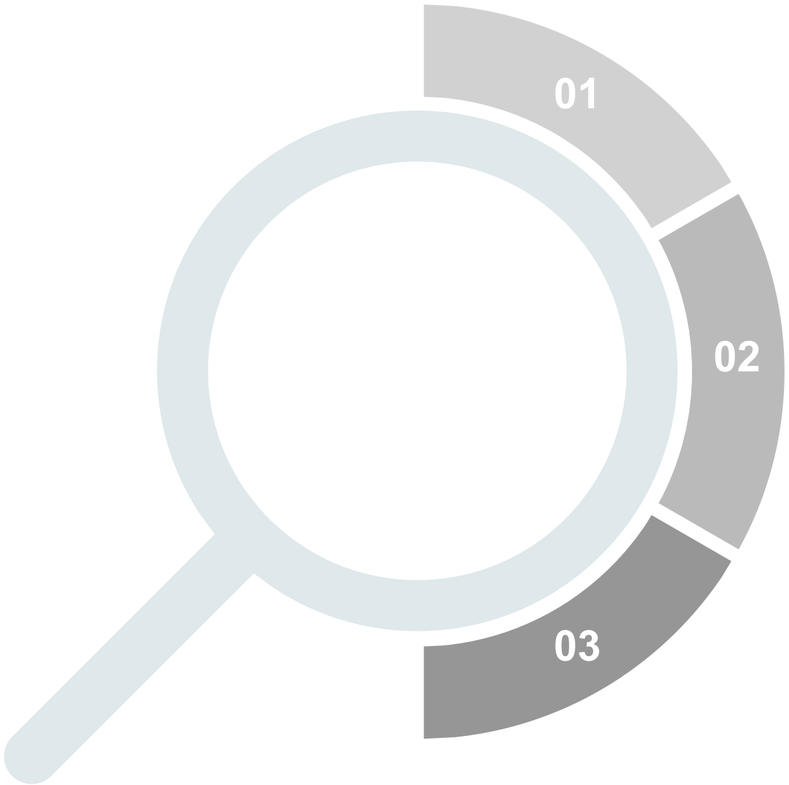

01

Generar un sistema de recomendación que permita conectar proveedores y consumidores dentro del ramo restaurantero.

02

Mejorar la calidad de las fotografías que suben los consumidores a la app de Yelp con la finalidad de que otros usuarios las vean con mayor nitidez.

03

Fortalecer el sector restaurantero brindando herramientas analíticas para mejorar, agilizar y ampliar el entendimiento del negocio y sus procesos..

Hallazgos

Ley de Zipf

La frecuencia de cualquier palabra es inversamente proporcional a su rango en la tabla de frecuencias.

La palabra más frecuente aparecerá el doble de veces que la segunda más frecuente, tres veces más que la tercera y así sucesivamente.

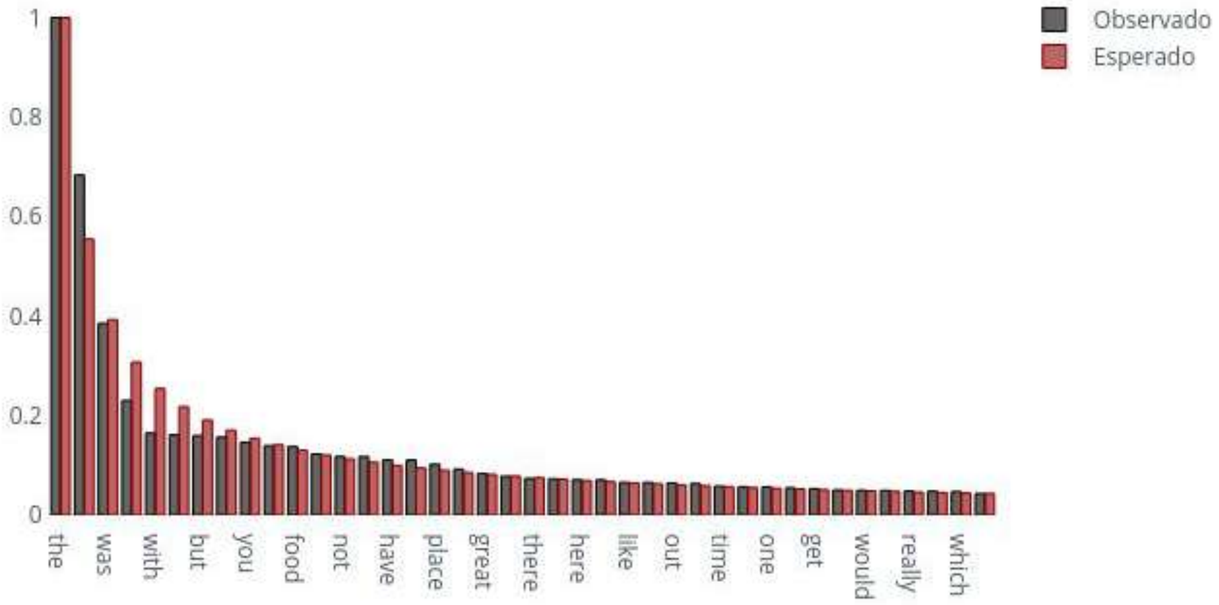

Ley logarítmica de Zipf

Al trazar sobre una escala logarítmica, el resultado será una aproximación lineal de los puntos.

Otra forma de verlo es con un gráfico log vs log, donde el eje X es el log(rango) y el eje Y es log(frecuencia).

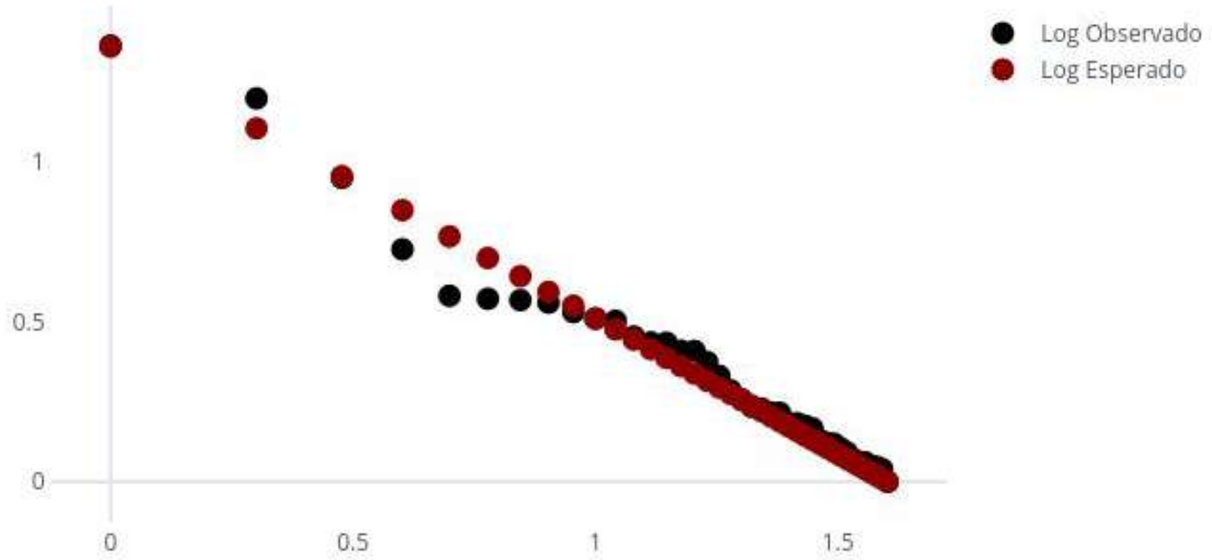

Part Of Speech Tagging

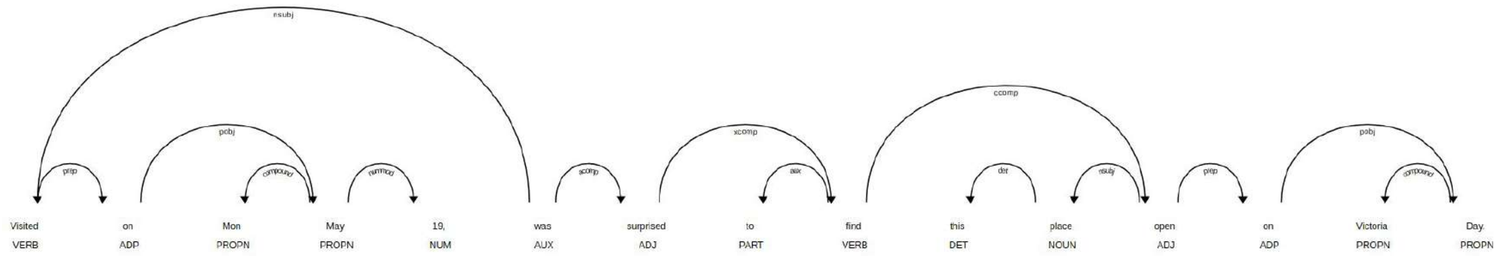

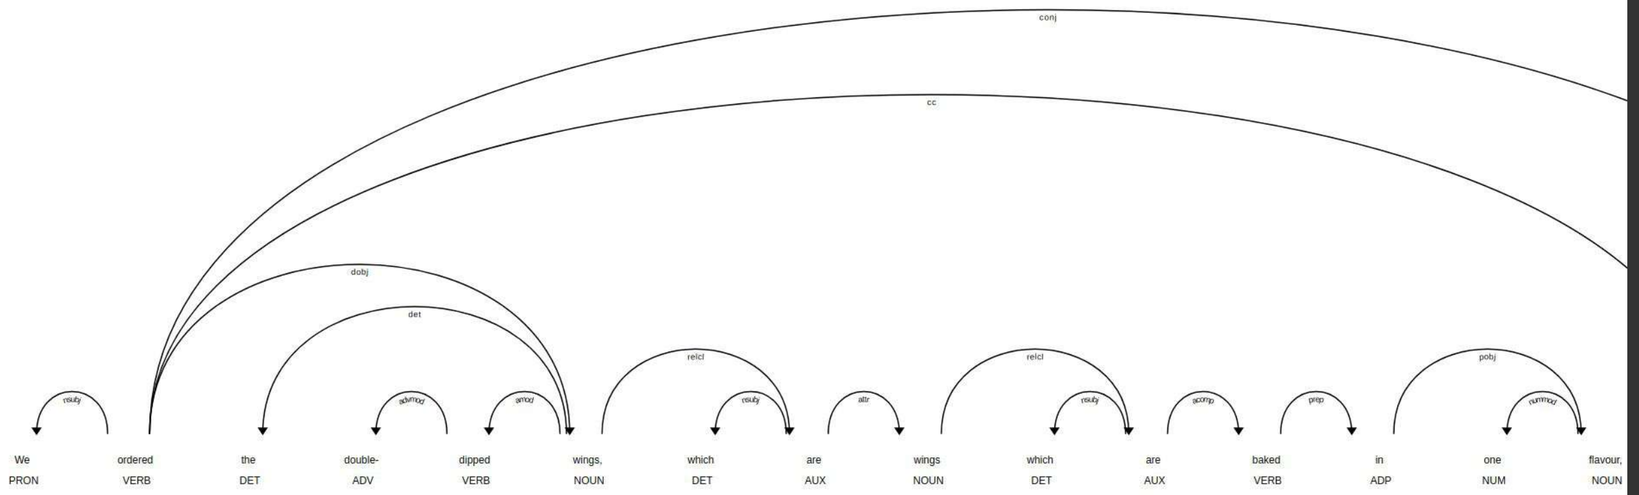

POST

El proceso de etiquetar cada palabra de un corpus con su categoría gramatical:

- sustantivos
- verbos
- adjetivos
- adverbios

Name Entity Recognition

Visited on Mon May 19 DATE , was surprised to find this place open on Victoria Day DATE . A handful of people were there, we sat on the patio. We ordered the double-dipped wings, which are wings which are baked in one CARDINAL flavour, and then fried with a second ORDINAL flavour. I have never tried this before, and this should be a huge reason to come to this place! We had two pounds QUANTITY one was " The Angry Mexican WORK_OF_ART " (Tequila Lime WORK_OF_ART then Hot) and " The Hoser WORK_OF_ART Eh!" (Maple and Rye Spiked BBQ Sauce, dusting of double smoked candied bacon). The server said The Hoser Eh recently won some wing competition award. The service was excellent, food was excellent. That afternoon there were 3 CARDINAL patrons on the patio that were arguing loudly for over 20min, they almost started to fight. Aside from that, would definitely come back again. There is pay and display parking along Avenue Road FAC .

NER

Busca localizar y clasificar palabras, sobre texto no anotado, categorías predefinidas como:

- personas
- organizaciones
- lugares
- expresiones de tiempo
- cantidades

Limpieza de texto

Remoción de:

Acentos	**Vectorización >> vectorizacion**
Signos de puntuación	**¡Atención!... >> atencion**
Simbolos	**♪♪♪ La, la, la ♪♪♪ 🤟 >> la la la**
Caracteres especiales	**#“Ciencia de datos” >> ciencia de datos**
Hapaxes	Palabras que aparecen una sola vez en un *corpus*

Lematización

El objetivo es eliminar inflexiones y asignar una palabra a su forma raíz.

dijéramos >> decir

Stopwords

Palabras sin significado como pronombres, preposiciones y artículos son removidas.

- **me, te, se, nos…**
- **a, ante, bajo, cabe, con…**
- **el, la los, las...**

N-gramas

Detecta frases de uso frecuente y las une para formar una sola palabra.

..ciudad de mexico.. >> cuidad_de

..ciudad de mexico.. >> cuidad_de_mexico

Word embeddings

word2vec

CBOW

Toma el contexto de cada palabra como entrada y trata de predecir la palabra correspondiente al contexto maximizando su probabilidad

Skip-gram

Está diseñado, por el contrario, para predecir el contexto dada una palabra.

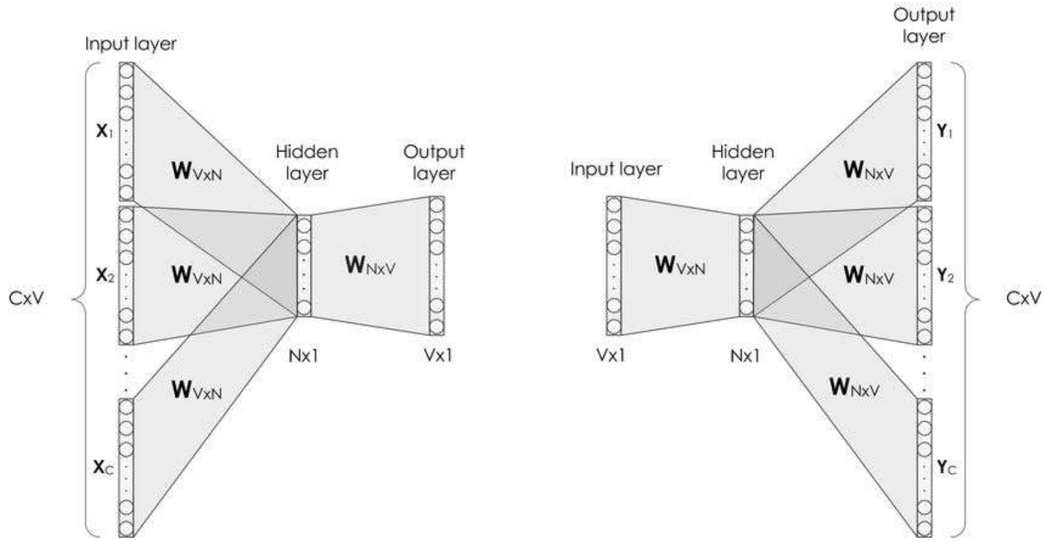

CBOW **Skip-gram**

Word2vec

CBOW

	Dimensión 1	Dimensión 2	Dimensión 3	...	Dimensión 98	Dimensión 99	Dimensión 100
analysis	-0.047615	0.150039	-0.018545	...	0.037166	0.146312	-0.033694
bias	0.148574	0.031524	-0.085909	...	0.151252	0.110774	0.028780
...	...	...	...	...	...	...	...
variance	0.205811	0.112766	-0.018472	...	-0.163403	0.191467	-0.028814
science	0.048734	0.009558	0.107020	...	-0.110675	0.18154	-0.053171

Semejanza de Términos

Similitud cosenoidal

Ejemplo 1

“pasta”

Token	Similitud
rigatoni	0.854
fettuccine	0.847
spaghetti	0.842
linguini	0.827

Semejanza de Términos

Similitud cosenoidal

Ejemplo 2

“tacos”

Token	Similitud
tostadas	0.838
quesadillas	0.807
pastor	0.788
carne_asada	0.771

Álgebra de palabras

Permite la deducción de un término desconocido a partir del análisis de la relación que se establece entre otros términos conocidos.

Una vez que las palabras son vectores, es posible hacer cálculos matemáticos con ellos.

- *king + woman - man = queen*
- *tortilla + indian - mexican = ?*
- *soup + italian - mexican = ?*
- *juice + night - day = ?*

Álgebra de palabras

Permite la deducción de un término desconocido a partir del análisis de la relación que se establece entre otros términos conocidos.

Una vez que las palabras son vectores, es posible hacer cálculos matemáticos con ellos.

- *king + woman - man = queen*
- *tortilla + indian - mexican = roti*
- *soup + italian - mexican = ?*
- *juice + night - day = ?*

Álgebra de palabras

Permite la deducción de un término desconocido a partir del análisis de la relación que se establece entre otros términos conocidos.

Una vez que las palabras son vectores, es posible hacer cálculos matemáticos con ellos.

- *king + woman - man = queen*
- *tortilla + indian - mexican = roti*
- *soup + italian - mexican = minestrone*
- *juice + night - day = ?*

Álgebra de palabras

Permite la deducción de un término desconocido a partir del análisis de la relación que se establece entre otros términos conocidos.

Una vez que las palabras son vectores, es posible hacer cálculos matemáticos con ellos.

- *king + woman - man = queen*
- *tortilla + indian - mexican = roti*
- *soup + italian - mexican = minestrone*
- *juice + night - day = ciroc*

Reducción de Dimensionalidad

(No Lineal)

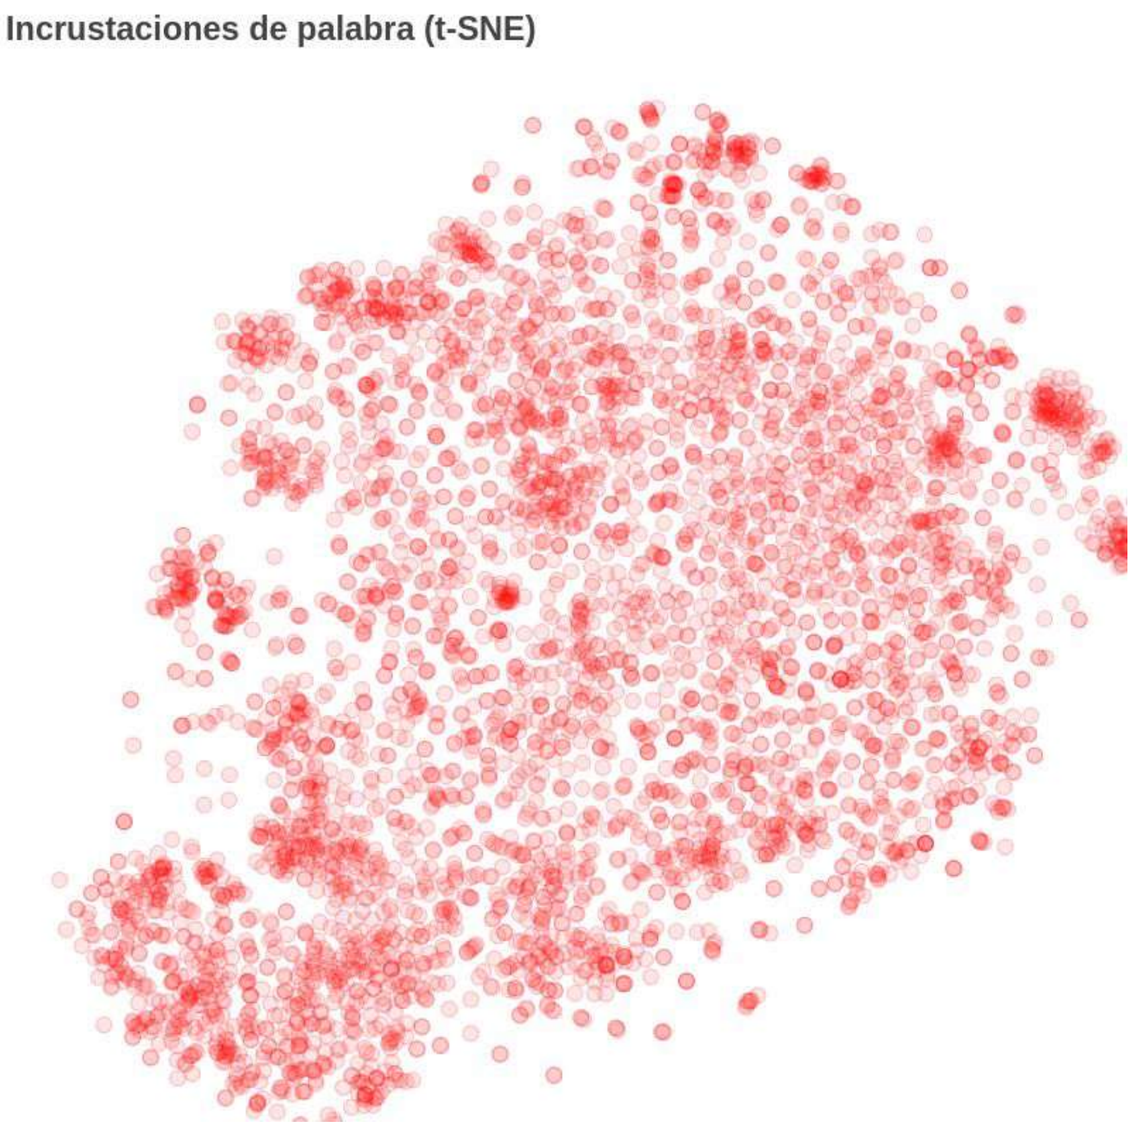

Modelación

Latent Dirichlet Allocation

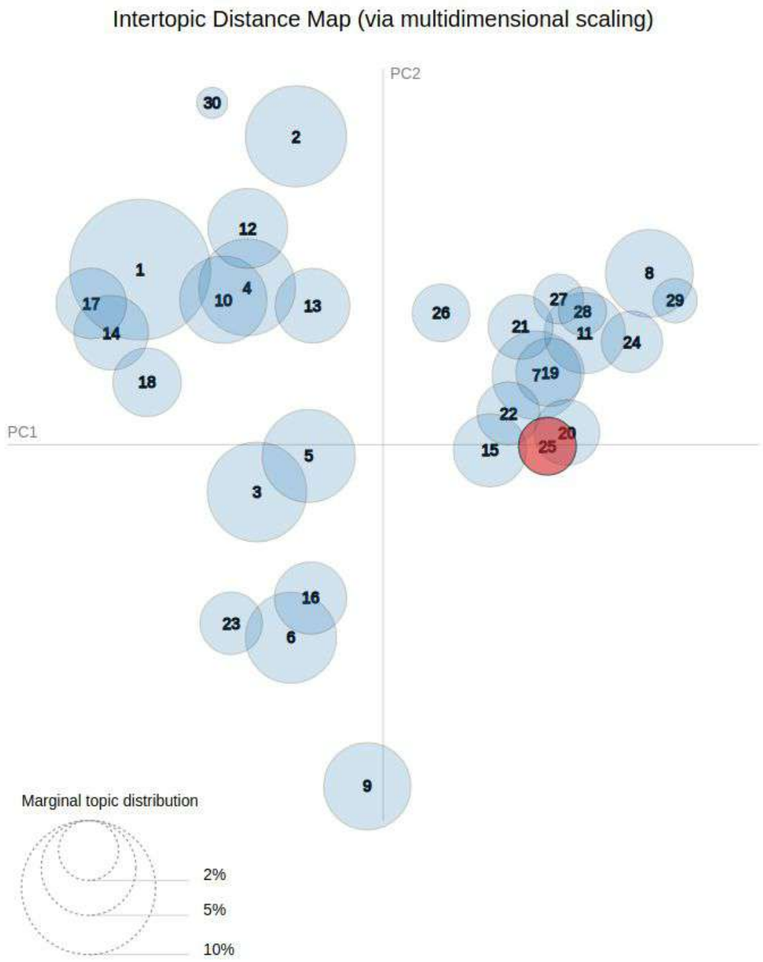

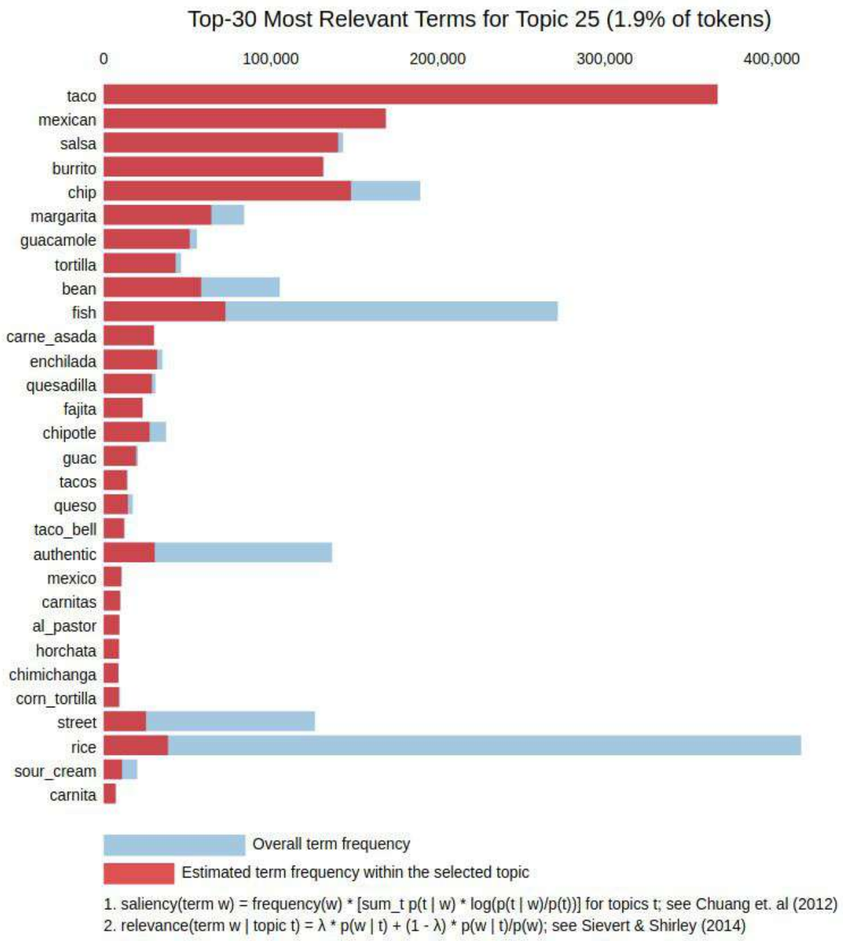

LDA

Encontrar temas o tópicos a los que pertenece un documento en función de la palabra que contiene.

Indica la probabilidad de que alguna palabra aparezca en un documento sobre un tópico en particular.

Nubes de palabra

30 Tópicos

Las etiquetas más grandes son las palabras que aparecen con mayor frecuencia en el *corpus*.

Sushi

Desayuno

Calidad-Precio

Bares y bebidas

Reservaciones

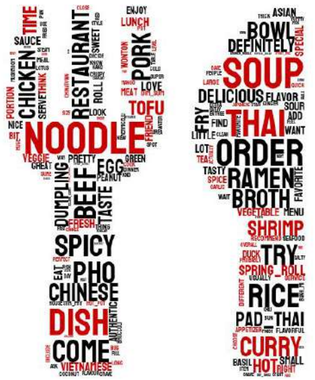

Sopas

Comida Mexicana

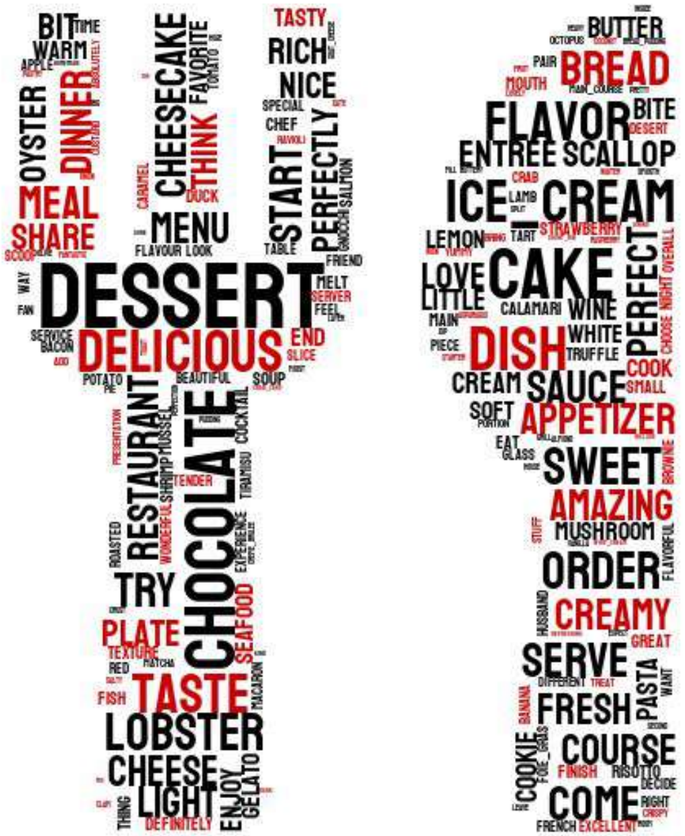

Postres

Análisis de sentimientos

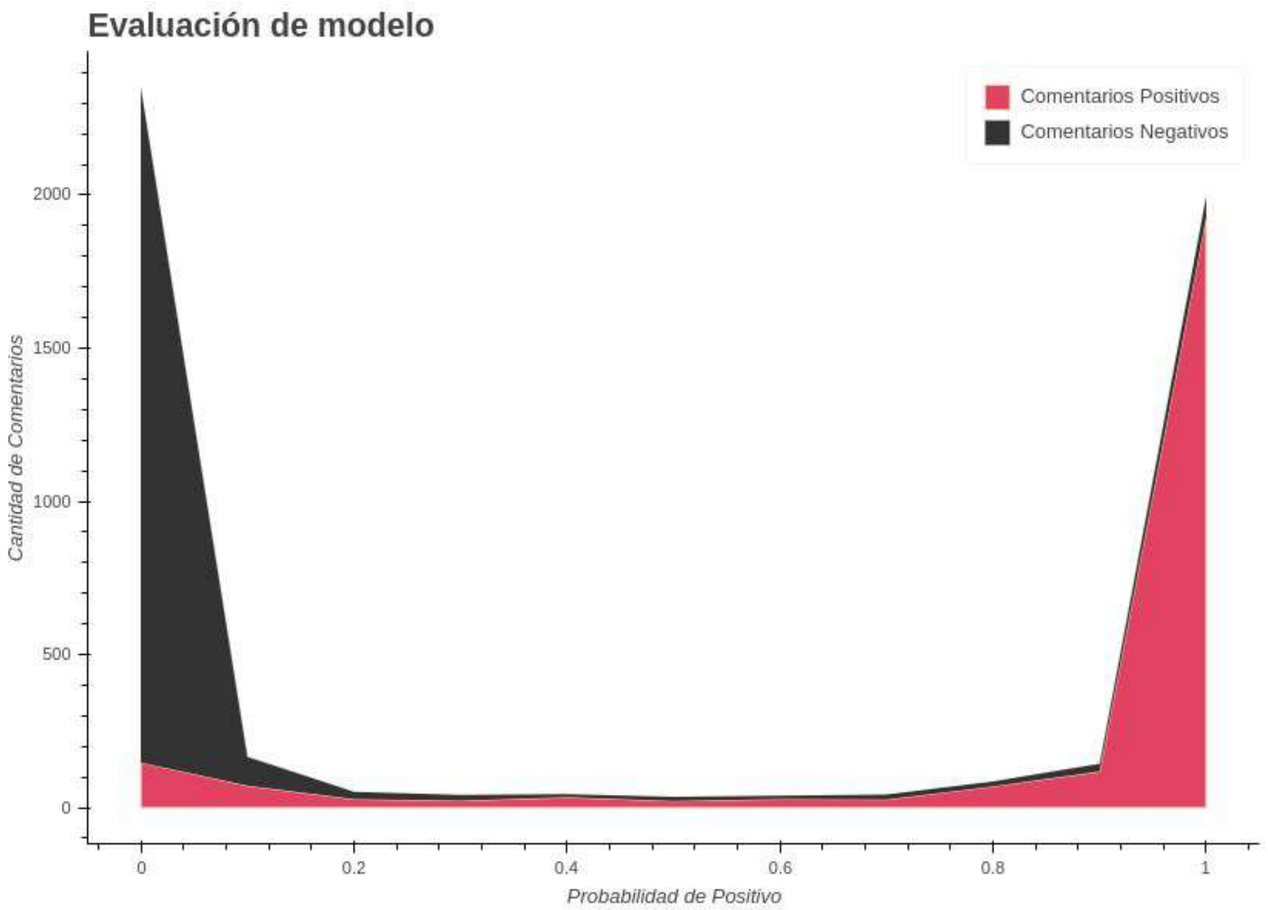

La arquitectura utilizada para modelar es de tipo *AARCNN*

Modelo de *Bow* + *CNN* + *RNN* + *Attention*

- Precision = 0.90
- Recall = 0.91
- **F1-score = 0.90**

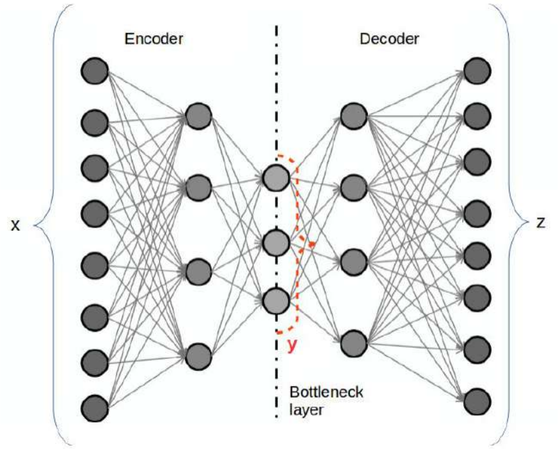

Autoencoder

Predicciones para una muestra de 5 fotografías:

Remoción de Ruido

Se tiene un conjunto de fotografías de comida y sus menús en baja resolución para miles de imágenes. Se hace uso de un Autoencoder para mejorar su calidad.

Estrategia

Sistema de Recomendación Dual

- ## Para los Restaurantes

  Reporte basado en los comentarios que han realizado los clientes sobre su negocio, segmentado en las categorías encontradas que le ayudará a identificar oportunidades de mejora en relación a su servicio, atención al cliente, preparación de alimentos, etc.

- ## Para los Clientes

  De acuerdo a sus preferencias (que debe establecer dentro de la aplicación) se le sugieren restaurantes basado también en las categorías que describen a cada uno de los establecimientos, “filtrando" los que se ajusten mejor a su perfil.

Ejemplo de
Uso y Aplicación

*"If you **enjoy a great Steak, Harbour Sixty will not disappoint you.** I have been here a few times now and **love their food and service.** The enormous shrimp cocktail (think it is sized 4-6) is fantastic. They are perfectly chilled and **the sauce has a nice lemon/horseradish mix.** The baseball filet is to die for, perfectly seasoned and cooked to perfection. They use a broiler that hits 1500 degrees, so the juices gets trapped in the meat instantly. **For dessert you have to try the baked Alaska.** The service and food is some of the best in the city!"*

Para Restaurantes

1. Se asocian todos los comentarios que van dirigidos al restaurante de todos los usuarios

2. Se predicen los tópicos del comentario

Clúster	Probabilidad de pertenencia
cortes selectos	0.305
salsas y aderezos	0.238
recomendaciones	0.232
postres	0.127

3. Se predice el sentimiento del comentario

- **Probabilidad para sentimiento positivo**

  0.999871

- **Probabilidad para sentimiento negativo**

  0.000129

Restaurante “X”	Polaridad Positiva	Polaridad Negativa
cortes selectos	1	0
salsas y aderezos	1	0
recomendaciones	1	0
postes	1	0
...	...	...

Supongamos que son 200 comentarios...

4. Se repite el paso 2 y 3 tantas veces como comentarios tenga el restaurante

Restaurante “X”	Comentarios +	Comentarios -	Total
cortes selectos	34	17	51
salsas y aderezos	11	0	11
recomendaciones	151	49	200
postres	26	73	99
servicio	128	8	136
comida rápida	50	54	104
...	...	...	...

5. Calcular la calificación del restaurante para cada rubro

Entregable:
Scorecard de 0 a 10

Restaurante “X”	Polaridad +	Polaridad -	Calificación
cortes selectos	0.66	0.33	6.6
salsas y aderezos	1.00	0.0	10.0
recomendaciones	0.75	0.25	7.5
postres	0.26	0.74	2.6
servicio	0.94	0.06	9.4
comida rápida	0.48	0.52	4.8
...	...	...	...

5. Calcular la calificación del restaurante para cada rubro

Entregable:
Scorecard de 0 a 10

Restaurante “Y”	Polaridad +	Polaridad -	Calificación
ensaladas	0.30	0.70	3.0
cortes selectos	0.93	0.07	9.3
comida rápida	0.78	0.22	7.8
calidad-precio	0.46	0.54	4.6
bar y bebidas	0.87	0.13	8.7
hotel y casino	0.22	0.78	2.2
...	...	...	...

5. Calcular la calificación del restaurante para cada rubro

Entregable:
Scorecard de 0 a 10

Restaurante “Z”	Polaridad +	Polaridad -	Calificación
desayuno	0.87	0.13	8.7
café	0.98	0.02	9.8
sushi	0.79	0.21	7.9
cortes selectos	0.89	0.11	8.9
comida vegana	0.13	0.87	1.3
comida italiana	0.52	0.48	5.2
...	...	...	...

Para Clientes

El cliente por sesión puede elegir 3 de las 30 categorías que son más importantes para él o ella. La sugerencia del recomendador será el restaurante con la calificación más alta del rubro más relevante seleccionado por el usuario, en caso de empate se toma la categoría más importante para el cliente y así sucesivamente.

Restaurante "X"	Polaridad +	Polaridad -	Calificación
cortes selectos	0.66	0.33	6.6
salsas y aderezos	1.00	0.0	10.0
recomendaciones	0.75	0.25	7.5
postres	0.26	0.74	2.6
servicio	0.94	0.06	9.4
comida rápida	0.48	0.52	4.8
...	...	...	...

Restaurante "Y"	Polaridad +	Polaridad -	Calificación
ensaladas	0.30	0.70	3.0
cortes selectos	0.93	0.07	9.3
comida rápida	0.78	0.22	7.8
calidad-precio	0.46	0.54	4.6
bar y bebidas	0.87	0.13	8.7
hotel y casino	0.22	0.78	2.2
...	...	...	...

Restaurante "Z"	Polaridad +	Polaridad -	Calificación
desayuno	0.87	0.13	8.7
café	0.98	0.02	9.8
sushi	0.79	0.21	7.9
cortes selectos	0.89	0.11	8.9
comida vegana	0.13	0.87	1.3
comida italiana	0.52	0.48	5.2
...	...	...	...

El algoritmo selecciona aquel restaurante con la calificación más alta de todos los que han sido calificados, en este caso el Restaurante "Y". Finalmente, este resultado más otros criterios como la cercanía son también considerados para dar la recomendación final.

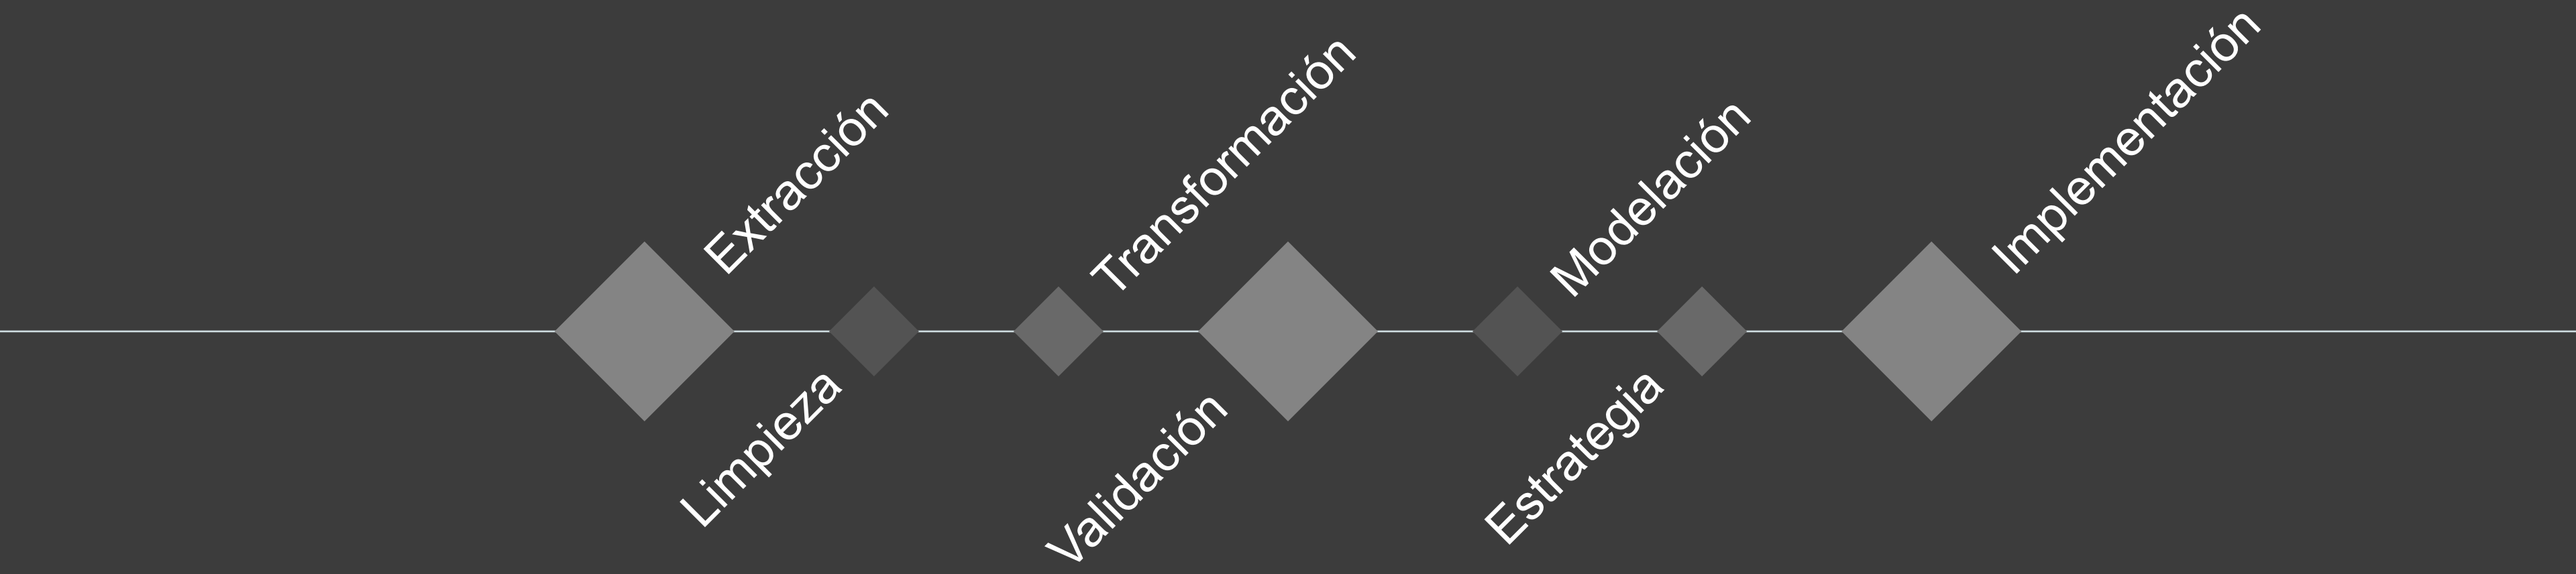

Conclusión

El sector restaurantero carece de un ecosistema analítico.

Este trabajo promueve el uso de herramientas fundamentadas en datos para ayudar a impulsar la toma de decisiones permitiendo mejorar, agilizar y ampliar el entendimiento de los negocios y los procesos del sector.

Siguientes Pasos

Entrenar con datos en español

Entrenar autoencoder por más tiempo y con más datos

Cuantizar y apificar los modelos

01

02

03

04

05

Modelar tópicos con procesos jerárquicos de Dirichlet

Entrenar con arquitecturas de tipo transformers como BERT o GPT

¡Gracias!

¿Preguntas?

Diplomado en Ciencia de Datos - Fernando Barranco Rodríguez

Correo: fernando.barranco.r@gmail.com